

SLAM 中的几何与学习方法
Geometric and Learning Approaches within
SLAM systems

盐粒

updated 2020 年 5 月 6 日

目录

1 Hello SLAM	1
1.1 SLAM 研究方向的变迁	1
1.1.1 不断进化的框架	1
1.1.2 多几何特征与多传感器	1
1.1.3 几何与学习的融合	2
1.2 为什么要写这本书	2
2 相机模型	3
3 几何视觉基础	4
3.1 几何特征	4
4 深度学习视觉基础	5
4.1 点线面的预测	5
4.2 深度图与法向量预测	5
5 位姿估计的模型	6
6 地图创建	7
7 非线性优化	8
7.1 光束法平差模型分析	8
7.2 经典的光束法平差解算方法	9
7.2.1 高斯牛顿方法	9
7.2.2 Leverberg-Marquart	10
7.3 稀疏结构化 BFGS 方法	11
8 优化中的位姿描述	12
8.1 四元素	12
8.2 李群与李代数	12
9 优化中的特征描述	12
9.1 点特征-逆深度	12
9.2 线特征-正交表示	12

10 经典的纯几何 SLAM	12
10.1 ORBSLAM (V1 and V2)	12
10.1.1 单目系统的初始化	12
10.1.2 姿态估计与优化	14
10.1.3 基于词袋的闭环检测	14
10.2 LSD-SLAM	15
10.2.1 整体流程	15
10.2.2 光度误差与深度误差	16
10.3 SVO	17
10.3.1 位姿估计	18
10.3.2 深度估计	18
参考文献	19

1 Hello SLAM

1.1 SLAM 研究方向的变迁

机器通过与环境发生一定的交互来完成相关的任务。为了将劳动者从繁杂、危险的环境中解放出来，机器被越来越广泛的应用在各种现实场景中，从扫地机器人到无人驾驶汽车。通过与环境发生一定的交互，机器可以自主的在较为复杂的场景中工作，因此它们也需要像人类一样的感知系统。视觉感知是感知系统的一部分，通过视觉传感器来完成机器的 6 自由度的运动估计和环境模型重建就是 SLAM (Simultaneous Localization and Mapping) 需要完成的主要工作。

1.1.1 不断进化的框架

SLAM 框架通过二三十年的发展，逐渐成熟起来。中间跨时代的作品都获得了巨大的论文引用量。

对与基于特征法的 SLAM 系统，PTAM 算是一个萌芽，它发表与 2007 年，指出了多线程，关键帧的发展道路。这篇文章中是 Tracking and Mapping 在两个线程中分开运行。其中 Mapping 部分是只处理关键帧的，并使用了局部 BA。The map 由两帧图像密集初始化，5 点法计算 pose。新的特征点是使用极线搜索来实现匹配的。比起这篇文章更以前的方法，它可以实时维护几千个点的地图。同样是基于点特征的系统，ORB-SLAM2 [4] 是一个灿烂的花朵。这个系统是由 Raúl Mur-Artal 博士等人提出的一个完备的基于特征点的纯视觉实时 SLAM 系统，适用于单目、双目和 RGB-D 相机，发表于 2017 年。作者在 2015 年第一次将单目版本 (ORB-SLAM [3]) 发表在 IEEE Transactions on Robotics (T-RO) 期刊上，这是一个基于纯特征点的单目实时 SLAM 框架。总体来说，该 ORB-SLAM 的两篇文章是基于特征的 SLAM 系统的大成之作，系统本身非常的完整，包含了稀疏地图，回环和优化环节。ORB-SLAM2 将传感器从单目扩展到双目和 RGB-D，成为了迄今为止影响力最大的特征法 SLAM 系统之一，为 SLAM 在工业界和学术界的发展作出巨大贡献。

1.1.2 多几何特征与多传感器

为了应对低纹理场景中特征点能力的限制，线特征被应用在系统中。




图 1: Caption

1.1.3 几何与学习的融合

1.2 为什么要写这本书

近年来，深度学习在更高层次的视觉任务中取得瞩目的成绩，如：物体识别，语义分割等，这些课题曾是传统视觉无法或很难解决的任务。正是由于深度学习拓展了我们对高层次视觉任务的想象，越来越多的 SLAM 开始在他们的框架中融合学习的方法，来改进位姿估计的准确程度和环境重建的效果。但是深度学习是一个非常宽广的领域，和 SLAM 相关的课题只是它的一个分支。本书将会挑选和聚焦和 SLAM 相关的深度学习话题，我们希望能通过这本书来介绍 SLAM 系统中使用的几何和深度学习的方法，帮助读者掌握最新的进展。从整体上理解基于几何的 SLAM 系统的技术细节，同时还能了解深度学习相关课题对传统几何 SLAM 的影响。

我们从 SLAM 中的基础的几何知识入手，先介绍相机模型，理解该问题中常见的坐标系，以及刚体变换的规则。然后按照 SLAM 中的每一个重要环节来详细介绍相关的知识。几何与学习特征的处理、优化问题的构建与求解，以及环境地图的创建与维护。在每个环节中，我们都深入的介绍相关的理论与工程细节，力求本书为读者带来快速的提高。几何与学习就像是 SLAM 的一双翅膀，未来的 SLAM 将提供更加的鲁棒、更加丰富的信息。最后，我们一起探讨 SLAM 的发展方向，畅想这个领域未来蓝图。

2 相机模型

SLAM 中的几何与学习进阶

3 几何视觉基础

3.1 几何特征

SLAM 中的几何与学习进阶

4 深度学习视觉基础

4.1 点线面的预测

4.2 深度图与法向量预测

5 位姿估计的模型

SLAM 中的几何与学习进阶

6 地图创建

SLAM 中的几何与学习进阶

7 非线性优化

前面的章节介绍了视觉里程计的前端相关的工作：特征的提取匹配、相机姿态求解和全局地图的构建。但是在前端获得的相机姿态和路标点存在误差，并且误差会随着时间的增加逐渐积累。因此本文使用光束法平差模型对上述信息进行优化，以获得准确的相机姿态求解和全局地图。在计算机视觉和摄影测量领域，光束法平差模型被广泛用来求解三角测量中的相机姿态估计和空间点坐标。因此，平差模型解算结果会直接影响机器人、无人机所提供服务的質量。

在传统的光束法平差模型解算方法中，高斯牛顿 (Gauss-Newton, GN) 方法作为一种具有快速收敛性的收敛方法，被广泛使用在光束法平差中，获得精准的相机位姿信息和 3 特征点信息。但是 GN 对初值的精度要求较高，在初值不好的情况下，将面临发散的危險。列温伯格-马夸尔特 (Leverberg-Marquart, LM) 方法通过增加阻尼项，保持了收敛的鲁棒性，但是这种方法使用置信区间来尝试阻尼的值，不能准确的获得下降方向，因此需要多次迭代才能完成收敛。本章主要探讨使用结构化的拟牛顿方法来替代 GN 和 LM 方法。在实验中，本方法对不同情况的初值体现了较强的鲁棒性、较高的精度和较少的迭代次数。

7.1 光束法平差模型分析

光束法平差 (bundle adjustment, BA) 是三维重建和视觉定位中非常关键的一步，在获得相机内参数、外参、影像特征点和空间 3D 物点坐标初始值之后，可以使用 BA 对包括相机的内参和外参在内的上述数据进行整体的优化，消除误差并获得精确的视觉信息。从数学本质上来说，光束法平差目标方程模型就是非线性最小二乘模型。在非线形优化问题的诸多解法中，牛顿法因为具备二阶收敛速度而得到广泛的应用，但是在迭代求解的过程中，牛顿法因计算复杂度过高，无法应用在实际的 BA 问题中。这种情况下，高斯牛顿方法通过忽略牛顿方法中产生的高阶导数很好的降低了算法的复杂度，在计算机视觉和摄影测量工程应用上被普遍接受。高斯牛顿方法的优势同时也蕴含着问题，被忽略的高阶导数导致此方法在求解问题对初值很敏感，并且容易发散。在针对光束法平差的研究中，有些研究人员着眼于为高斯牛顿方法提供更高进度的初值，以保证问题收敛。但是，提高初值精度时，往往需要更高精度的采集设备和人工预处理过程。有些研究人员聚

焦在平差模型的稀表示上, SBA[1] 与 sSBA[2] 从 Jacobian 矩阵的稀疏性编码的角度优化求解速度和存储效率。ParallaxBA[3] 在影像序列中, 使用影像间的视差角等角度信息代替直角坐标进而降低 Jacobian 矩阵的稀疏性。Multicore BA[4] 利用计算机并行计算方式, 通过使用多核 CPU 和 GPU 进行算法加速。

光束法平差被认为是摄影测量和计算机视觉中的黄金定律, 而光束法平差的本质是关于相机姿态 () 与三维点 () 的最小二乘优化问题。相机姿态包含平移矩阵和旋转矩阵。一组同名像点对应着一个空中的三维点, 通过相机观测三维点在影像上坐标为。通过投影方程对三维点进行重投影, 估计重投影像点:

$$g(c_i, p_i) = R^T(T_i - P_j) \quad (7.1)$$

其中函数是把物方的三维点投影成二维像点的观测方程。这样基于每个投影像点将建立起一个误差方程:

$$r_{i,j} = g(c_i, p_i) - z'_{ij} \quad (7.2)$$

在公式 (4.3) 中, 是一个协方差矩阵, 同一个传感器观场进行观测的时候, 我们认为误差之间是相互独立的, 故通常作为一个对角阵存在, 在实际的工作中通常取单位阵。通过对目标方程的解算, 我们最终可以获得优化的结果。下面两个公式从论文中截图。通过反投影方程, 将相机 Pose c 和 landmark p 投影到图片坐标。

7.2 经典的光束法平差解算方法

7.2.1 高斯牛顿方法

高斯牛顿方法从牛顿方法简化而来, 因此在剖析高斯牛顿方法发散原因之前, 本文首先介绍牛顿优化方法。通过牛顿法的介绍, 可以更加容易理解高斯牛顿发散的数学机理。在数值优化领域, 牛顿法因具有较快的收敛速度, 被用来求解无约束优化问题。这个方法的主要思路是在迭代点处进行泰勒展开, 使用展开式对目标方程进行近似。因此非线性问题就可以转化为线性问题, 并使用求二次模型的极小点的方式来获取新的迭代点。通过多次迭代, 达到满足的精度为止。对公式 (4.3) 进行一阶泰勒展开: (4.4)

如果非奇异, 那么, 其中,。在之前已经描述过了, 牛顿法具有不低于二阶的收敛速度, 但是该方法在遇到 BA 问题时, 求解 Hessian 矩阵工作量巨

大，同时不能保证目标函数的 Hessian 矩阵在每个迭代点处都能保持正定。为了利用牛顿法的优势，避免不足，出现了 Gauss-Newton 等 BA 解法。正常情况下，其中为 Hessian 矩阵， $=$ 。在 Gauss-Newton 方法中，忽略公式的第二项，使用来代替 Hesse 矩阵，求解方程的下降方向。

图 4.1 高斯牛顿法的伪码算法过程在 GN 方法中， Δ 是下降方向。可以看出缺少高阶导数信息的高斯牛顿算法在迭代求解过程中必须满足 Hessian 矩阵正定的条件，进而要求 Jacobian 矩阵必须是列满秩，不然算法失效。而 Jacobian 矩阵是相机与三维特征点之间的表示方式 [[

]] 是随着输入参数的变化而变化的。因此对 Jacobian 矩阵的要求就变成了对观测初值的要求，这就是高斯牛顿方法对初值敏感的根本原因。

7.2.2 Levenberg-Marquart

有上面内容可知，对于 GN 方法，使用 $J^T J$ 矩阵近似 Hessian 矩阵很容易发生奇异，因此，光束法平差问题常常无法解算。为了克服 GN 方法的缺点，LM 方法被提出来，并作为应用最为广泛的方法求解 BA 模型。LM 算法可以表示为公式 (4.5) (4.5)

其中矩阵表示单位阵，LM 算法的原理是在近似 Hessian 矩阵上的对角线上加上一个阻尼值，从而近似 Hessian 矩阵的奇异问题。通过观察公式 (4.5)，LM 方法是一种结构化的方法，其中包含两个部分：与，可以通过调整的大小，调节与之间的比重。当特别大时，可以忽略，即公式 (4.5) 可以变成梯度下降方法公式 (4.6)：(4.6)

当特别小时，可以忽略，求解方法即变成 GN 方法。因此可以把 LM 方法看做是最速梯度下降法和高斯牛顿法的结合。使用置信区间来更新当，如果当前次迭代可以得到比前一次迭代更小的优化结果，此时公式 (4.5) 就需要减小的大小 λ ；假如不满足条件时，需要增大值 λ 。

进入的优化环节的初值情况是无法控制的，与高斯牛顿的初值敏感特点一样，LM 方法对于初值较差的情况，LM 同样是死板的调整阻尼值，不能根据当前迭代的实际情况来完成阻尼的更新，因此 LM 方法常常在需要较多次的迭代才能完成。从 4.4.2 小节中的实验结果可以看出，LM 通常杂迭代初期会有一个近似乎平原区域，其主要原因就是因为在阻尼参数的选择不恰当，无法获得好的下降方向。

7.3 稀疏结构化 BFGS 方法

在上述篇幅中，我们对高斯牛顿方法和 LM 方法进行了分析，清楚的把这两种方法缺陷及其成因展现在读者眼中。本节将针对高斯牛顿和 LM 出现的问题，结合稀疏结构化 BFGS 算法提出更加鲁棒的光束法平差模型解算方法。

4.3.1 BFGS 正定保持特性 BFGS 是一种常用的拟牛顿方法，由于该方法经过秩 2 修正，因此在迭代求解过程中，对于输入的正定矩阵，在满足情况的条件下，能保持正定性。(4.7) 其中，是两次迭代之间的残差向量。另外，是雅克比矩阵的差，然后，进行反投影误差的求解，

4.3.2 结构化的 BFGS 方法在上面的分析中我们明白高斯牛顿方法无法保持矩阵正定，现在我们要为其加入一个正定矩阵，使得在任何时候都能够保持正定，这样可以解算任意情况的初值。如下式所示：(4.8) 在本方法中通过 BFGS 算法来更新，具体的证明过程可以参考优化书籍，不再赘述。

由于 BFGS 对于正定性质的保持能力，假设为正定矩阵，使用 BFGS 算法更新时，只要，并且那么可以保障的正定性，进而为正定矩阵，保证了下降方向始终是正确的。

(4.9)

因此上面的式子中，使用近似 Hessian 矩阵中的含有高阶导的部分，我们通过 BFGS 方法来更好的模拟 Hessian 矩阵。通过公式 (4.9) 获得的是一个密集矩阵，由于 BA 问题涉及到的矩阵的维数非常大，因此对于密集矩阵的求解将会非常困难。因此本文根据 Hessian 矩阵的低阶导数信息的稀疏化高阶导数矩阵，因此可以实现稀疏化的，记做。(4.10)

如公式 (4.11) 所示，可以通过上面的稀疏化的矩阵，在求解下降方向以后，可以顺利的对光束法平差问题进行解算。与 LM 方法相比，本方法在迭代点远离真值时，依然能保持超线性收敛速度，随着迭代的进行，当前迭代点逐渐接近真值，本方法中的高阶导数矩阵的作用就比较微弱，本方法以高斯牛顿方法进行收敛，同样保持超线性收敛速度。(4.11) 其中表示 sBFGS 方法下降方向。

8 优化中的位姿描述

8.1 四元素

8.2 李群与李代数

9 优化中的特征描述

9.1 点特征-逆深度

9.2 线特征-正交表示

10 经典的纯几何 SLAM

10.1 ORBSLAM (V1 and V2)

ORB-SLAM2 [4] 是由 Raúl Mur-Artal 博士等人提出的一个完备的基于特征点的纯视觉实时 SLAM 系统, 适用于单目、双目和 RGB-D 相机, 发表于 2017 年。作者在 2015 年第一次将单目版本 (ORB-SLAM [3]) 发表在 IEEE Transactions on Robotics (ToR) 期刊上, 这是一个基于纯特征点的单目实时 SLAM 框架。总体来说, 该 ORB-SLAM 的两篇文章是基于特征的 SLAM 系统的大成之作, 系统本身非常的完整, 包含了稀疏地图, 回环和优化环节。ORB-SLAM2 将传感器从单目扩展到双目和 RGB-D, 成为了迄今为止影响力最大的特征法 SLAM 系统之一, 为 SLAM 在工业界和学术界的发展作出巨大贡献。

在特征匹配、跟踪和回环检测等所有环节全部采用统一的 ORB 描述子, 通过地图复用, 有效提高了系统的鲁棒性。该系统分为四个模块, 分别是前端、局部建图和回环检测以及闭环, 系统使用 3 个线程。。下面我们着重介绍 ORB-SLAM2 中重要的几个模块。

10.1.1 单目系统的初始化

系统有两个初始化模块, 双目和 RGB-D 共用一个模块, 单目有自己的一个初始化模块, 在追踪开始后, 根据输入图像的样式, 进去相应的初始化程序。相比于双目和 RGB-D, 单目不具有尺度, 因此更加的复杂, 这里我们介绍单目的初始化过程。首先是对连续的两帧 (F_i 和 F_{i+1}) 提取特征点,

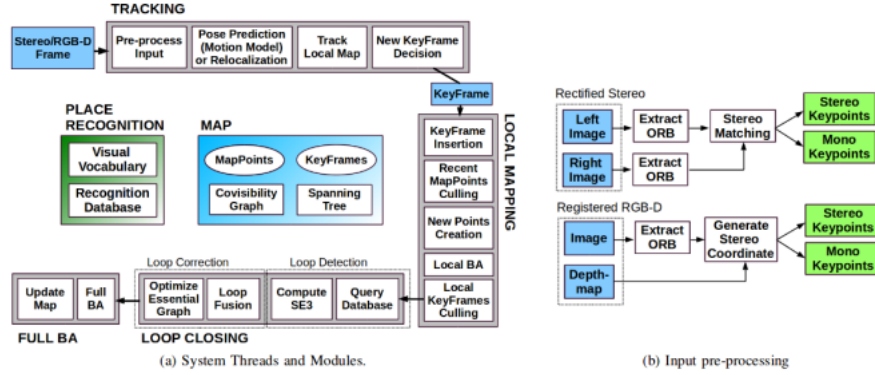


图 2: ORB-SLAM2 系统框图。[4]

如果他们满足特征匹配数量的约束。就进一步计算两帧之间的位姿。如果，不是连续的两帧那么就重新开始。

为了提升初始化的精度，作者同时估计两帧图像之间的单应矩阵（Homograph）和基础矩阵（Fundamental），单应矩阵可以用来处理平面之间/较小视差角的旋转与平移，基础矩阵则能处理更普遍的特征点。对于两帧图像之间的同名点，系统同时估计上述的两个矩阵 H_{cr} 和 $F(cr)$ ，其中 c 和 r 分别表示当前帧和参考帧。对于同名点随机选择八个点，并建立很多组。然后通过公式10.1将这两个矩阵分别将一帧图像中同名点转换到另一帧图像上，来计算同名点在每帧图像上的像素距离。

$$S_M = \sum_i (\rho_M(d_{cr}^2(x_c^i, x_r^i, M)) + \rho_M(d_{rc}^2(x_c^i, x_r^i, M))) \quad (10.1)$$

这里 i 表示同名点的数量， M 为 H_{cr} 或 $F(cr)$ 矩阵中的一个。最后，利用公式10.2来比较两个误差的大小，并选择一个矩阵。

$$R_H = \frac{S_H}{S_H + S_F} \quad (10.2)$$

在 ORB-SLAM 中，如果 $R_H > 0.045$ 选择单应矩阵，否则选择基础矩阵来初始化两帧图像之间的位姿。在完成位姿之后，系统利用该信息和同名点信息进行路标点的三角化（Triangulation）工作，创建稀疏地图。

10.1.2 姿态估计与优化

对于相机姿态的估计是 SLAM 系统的一个重要任务,这个环节为 AR/VR,机器人和无人驾驶等应用提供支持。在 ORB-SLAM2 中,利用相机基线来实现 RGB-D 向双目相机的转化。

- 系统在 2D 特征提取中为了使特征分布更加均匀,将图像分块提取特征。对于双目和 RGB-D 相机,系统可以直接获得特征点的 3D 信息,而单目相机需要在后面进行三角化操作。
- 完成当前帧的特征提取之后,系统通过追踪参考帧或使用运动模型的方式获得当前帧的初始 6D 位姿。两个方法都是先给当前相机的位姿赋一个值,然后再用重投影误差去优化。然后使用局部地图再优化一遍,局部建图模块是利用前端输入的关键帧插入局部地图进行局部优化。
- 如果检测出来是关键帧,另一个线程基于共视图的优化。

ORB-SLAM 的这种相机位姿估计策略非常鲁棒,尤其是当检测的特征点充足时,可以实现高精度的位姿估计。

10.1.3 基于词袋的闭环检测

对于基于 Frame-to-Frame 和 Map-to-Frame 的 SLAM 系统,随着追踪时间的增长,系统也在不断积累着误差,这种现象被称之为系统漂移(drift)。回环检测(Loop Closure)是一种消除漂移的有效解决方案。闭环检测是在历史轨迹中查找是否存在与新关键帧具有相同观测的和约束的关键帧,筛选过程主要包括位置识别和几何验证。

在 ORBSLAM2 中,闭环检测线程通过词袋法(DBoW2)加速闭环匹配帧的筛选。这种方法的目的是用一种更加抽象、更加高效的特征集合来描述一幅图像。通过 DBoW2,作者训练了一个较大的特征字典。对于每一帧图像中提取的特征,只要在字典树中逐层查找,最后都能找到与之对应的单词。最后可以使用一个分布或直方图来准确的描述这个图像。从图3(a)中可以看到 Pose2 和 Pose6 之间的共同观测。并通过共同观测计算两帧图像之间的旋转矩阵和平移矩阵,对于单目相机,还要通过 Sim3 优化尺度。然后在上一步求得的 Sim3 和对对应同名点的基础上,纠正了当前帧以及所有有同视关系的关键帧的位姿,以及路标点。

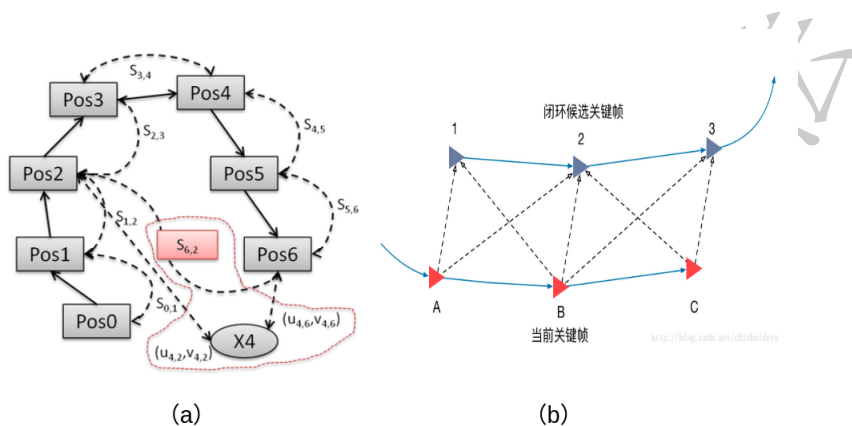


图 3: 闭环检测检测

10.2 LSD-SLAM

LSD-SLAM (large-scale direct monocular SLAM) [1] 是发表在 ECCV2014 的直接法的 SLAM。与 ORB-SLAM 等所用的特征法不同，直接法视觉里程计 (VO) 是直接利用图像像素点的灰度信息来构图与定位，克服了特征点提取方法的局限性，可以使用图像上的所有信息。该方法在特征点稀少的环境下仍能达到很高的定位精度与鲁棒性，而且提供了更多的环境几何信息，这在机器人和增强现实应用中都是非常有意义的。

这篇文章的第一作者 Jakob Engel 对直接法的发展作出了很大的贡献。本篇文章提出的方法能够构建大尺度的，全局一致性的环境地图。除了能够基于直接图像配准得到高度准确的姿态估计外，还能够将三维环境地图实时重构为关键帧的姿态图和对应的半稠密的深度图。这些都是通过对大量像素点对之间的基线立体配准结果滤波后得到的。算法提出了计算尺度漂移的公式，即便是当图像序列的场景尺度变化较大时也能够适用。

10.2.1 整体流程

算法有三个主要组成部分，分别为图像跟踪、深度图估计和地图优化。如图 4 所示。

- 图像跟踪：连续跟踪从相机获取到的新“图像帧”。也就是说用前一帧图像帧作为初始姿态，估算出当前参考关键帧和新图像帧之间的刚体变换 $\xi \in se(3)$ 。




图 4: Pipeline of LSD-SLAM [1]

- 深度图估计：使用被跟踪的“图像帧”，要么对当前关键帧深度更新，要么替换当前关键帧。深度更新是基于像素小基线立体配准的滤波方式，同时耦合对深度地图的正则化。如果相机移动足够远，就初始化新的关键帧，并把现存相近的关键帧图像点投影到新建的关键帧上。
- 地图优化模块：一旦关键帧被当前的图像替代，它的深度信息将不会再被进一步优化，而是通过地图优化模块插入到全局地图中。为了检测闭环和尺度漂移，采用尺度感知的直接图像配准方法来估计当前帧与现有邻近关键帧之间的相似性变换。

10.2.2 光度误差与深度误差

关键帧是 LSD-SLAM 系统中重要的媒介。启动 LSD-SLAM 系统时，只需要初始化首帧关键帧即可，而关键帧深度信息初步设定为一个方差很大的随机变量。在算法运行最开始的几秒钟，一旦摄像头运动了足够的平移量，LSD-SLAM 算法就会“锁定”到某个特定的深度配置，经过几个关键帧的传递之后，就会收敛到正确的深度配置。

$$E(\xi) = \sum_i (I_{ref}(p_i) - I(w(p_i, D_{ref}(p_i), \xi)))^2 \quad (10.3)$$

公式 10.3 是当前帧 I 与参考帧 I_{ref} 之间的光度误差。其中 $w(p_i, D_{ref}(p_i), \xi)$ 是将这些像素重投影到参考帧 I_{ref} 。一旦新图像帧被选择成为关键帧，把上一帧关键帧的兴趣点投影到新创建的关键帧上得到这一帧的兴趣点。之后，深度图被平均至逆深度为 1，就可以使用相似变换 $\text{sim}(3)$ 来计算关键帧之间的边，因为相似变换 $\text{sim}(3)$ 可以较好地结合关键帧之间的尺度缩放差异。

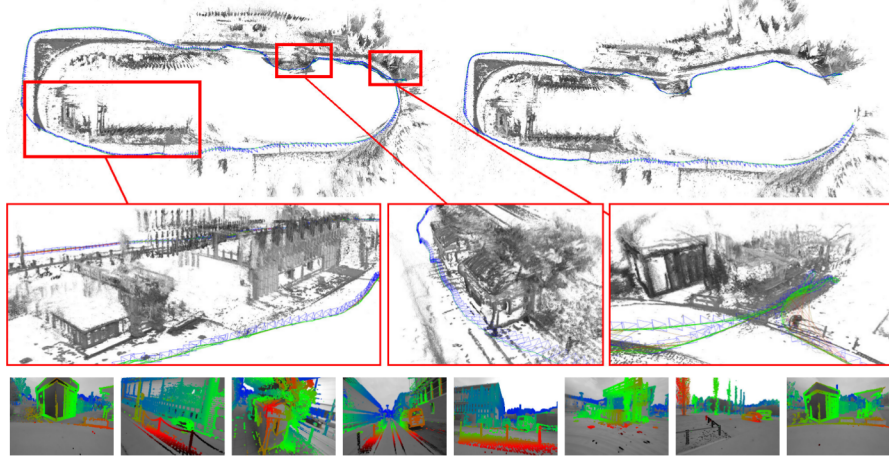


图 5: LSD-SLAM 中的闭环检测模块。左图是闭环检测的效果，右图是没有闭环检测。[1]

除了包含光度测量残差 r_p ，该论文还引入深度残差 (depth residual) r_d 来惩罚关键帧之间的逆深度偏差，能直接够估计出帧间的相似变换。LSD-SLAM 论文中使用的误差函数 $E(\xi_{ji})$ ，

$$E(\xi_{ji}) = \sum \left\| \frac{r_p^2(p, \xi_{ji})}{\sigma_{r_p(p, \xi_{ji})}^2} + \frac{r_d^2(p, \xi_{ji})}{\sigma_{r_d(p, \xi_{ji})}^2} \right\| \quad (10.4)$$

其中 r_d 是深度残差， $\sigma_{r_p}^{-2}$ 和 $\sigma_{r_d}^{-2}$ 分别是光度残差和深度残差的逆方差。

10.3 SVO

全称 fast Semi-direct monocular Visual Odometry (半直接视觉里程计)，是苏黎世大学机器人感知组的克里斯蒂安·弗斯特 (Christian Forster 等人于 2014 年 ICRA 会议上发表的工作。2016 年扩展了多相机和 IMU 之后，写成期刊论文，称为 SVO 2.0。与基于特征法的 ORB-SLAM 和直接法的 LSD-SLAM 不同，SVO 提取了稀疏点，但是使用直接法来做图像之间的对齐，故称它为半直接法。高翔博士在 LDSO [2] 中同样使用特征点和光度，特征的主要作用是实现闭环检测，只不过现在半稠密的概念已经不如以往流行了。SVO 结合了直接法和特征点法，但是特征点只是从关键帧中提取，以保证系统的运行速度。SVO 算法分成两部分：位姿估计，深度估计。下文详细介绍这两个模块。




图 6: 深度的高斯-均匀分布。

10.3.1 位姿估计

对稀疏的特征块使用 direct method 配准，获取相机位姿；通过获取的位姿预测参考帧中的特征块在当前帧中的位置，由于深度估计的不准导致获取的位姿也存在偏差，从而使得预测的特征块位置不准。由于预测的特征块位置和真实位置很近，所以可以使用牛顿迭代法对这个特征块的预测位置进行优化。特征块的预测位置得到优化，说明之前使用直接法预测的有问题。利用这个优化后的特征块预测位置，再次使用直接法，对相机位姿 (pose) 以及特征点位置 (structure) 进行优化。而特征点值从关键帧中提取，文章使用重投影误差来做 pose refinement。

10.3.2 深度估计

除了 tracking 线程，svo 还有一个 mapping 线程。2d 特征的深度估计是在这个线程中完成的。SVO 中使用高斯-均匀分布对逆深度信息建模。如果当前帧被选为关键帧，就提取关键帧上的新特征点，这些特征点并未有对应的深度信息，因此需要获得计算深度。如果进来一个普通帧，就用普通帧的信息，更新所有种子点的概率分布。于是你从这条极线的一个端点走到另一个端点，把每处的图像块都和参考的去比较，就可以找到正确的匹配。如果某个种子点的深度分布已经收敛，就把它放到地图中，供追踪线程使用。

参考文献

- [1] Jakob Engel, Thomas Schöps, and Daniel Cremers. Lsd-slam: Large-scale direct monocular slam. In *European conference on computer vision*, pages 834–849. Springer, 2014.
- [2] Xiang Gao, Rui Wang, Nikolaus Demmel, and Daniel Cremers. Ldso: Direct sparse odometry with loop closure. In *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 2198–2204, 2018.
- [3] Raul Mur-Artal, Jose Maria Martinez Montiel, and Juan D Tardos. Orb-slam: a versatile and accurate monocular slam system. *IEEE transactions on robotics*, 31(5):1147–1163, 2015.
- [4] Raul Mur-Artal and Juan D Tardós. Orb-slam2: An open-source slam system for monocular, stereo, and rgb-d cameras. *IEEE Transactions on Robotics*, 33(5):1255–1262, 2017.